# Regressão simples

Danilo de Paula Santos/Gabriela Wunsch Lopes 17/10/2019

```
# install.packages("compareGroups")
# install.packages("ggplot2")
# install.packages("data.table")

library("compareGroups")
library("ggplot2")
library("haven")
library("ggpubr")
library("dplyr")
library(knitr)
```

#### Suwit dataset

Estudo da relação entre infecção por ancilóstomo e perda de sangue. Tailândia 1970

```
suwit <- read_sav("Bancos/Suwit.sav")</pre>
```

Primeiro passo: verificar o banco

```
compare_suwit <- compareGroups( ~ ., data = suwit)
summary(compare_suwit)</pre>
```

```
##
##
   --- Descriptives of each row-variable ---
##
## -----
## row-variable: Identificação
##
##
       N mean sd
                      lower
                               upper
## [ALL] 15 8
             4.472136 5.523414 10.47659
##
## -----
## row-variable: número de vermes
##
       N mean sd
                        lower
                                 upper
## [ALL] 15 552.4 513.9007 267.8113 836.9887
##
## row-variable: Perda de sangue por dia
##
       N mean
                 sd
                           lower
                                   upper
## [ALL] 15 33.45267 24.85249 19.68982 47.21551
```

```
tabela_suwit <- createTable(compare_suwit)
tabela_suwit</pre>
```

```
##
## -----Summary descriptives table ------
##
##
##

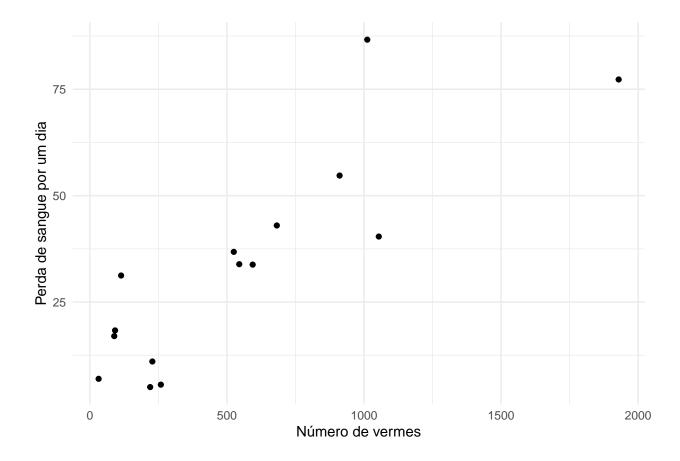
[ALL] N
##
N=15
##

## Identificação 8.00 (4.47) 15
## número de vermes 552 (514) 15
## Perda de sangue por dia 33.5 (24.9) 15
```

Segundo passo: verificar linearidade com gráfico de dispersão e identificar pontos

1) Gráfico de dispersão

```
suwit_scatter <- ggplot(suwit, aes(x = vermes, y = perda_sangue))+
  geom_point() +
  scale_x_continuous("Número de vermes") +
  scale_y_continuous("Perda de sangue por um dia") +
  theme_minimal()</pre>
```



2) Identificando pontos: qual o ID do ponto mais extremo na vertical?

```
suwit %>%
filter(perda_sangue>75, vermes<1500)</pre>
```

```
## # A tibble: 1 x 3
## id vermes perda_sangue
## <dbl> <dbl> <dbl> ## 1 13 1012 86.7
```

#### Terceiro passo: estimar modelo

O modelo de regressão linear simples para a perda de sangue da amostra em função da variável preditora "número de vermes" pode ser visualizado como uma linha reta no gráfico, estimada pelo método dos mínimos quadrados, que corresponde à melhor representação de uma linha que percorre os dados tentando minimizar a distância entre a linha e as observações (pontos)

```
##
## Call:
```

```
## lm(formula = perda_sangue ~ vermes, data = suwit)
##
## Residuals:
##
      Min
                1Q Median
                                3Q
                                       Max
##
  -15.846 -10.812
                     0.750
                             4.356
                                    34.390
##
## Coefficients:
##
                Estimate Std. Error t value Pr(>|t|)
## (Intercept) 10.847327
                           5.308569
                                      2.043
                                              0.0618 .
## vermes
                0.040922
                           0.007147
                                      5.725 6.99e-05 ***
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 13.74 on 13 degrees of freedom
## Multiple R-squared: 0.716, Adjusted R-squared: 0.6942
## F-statistic: 32.78 on 1 and 13 DF, p-value: 6.99e-05
```

Além da estimativa de B0 / intercepto (Intercept) e B1/ inclinação (vermes), também observamos o resultado de um teste de significância do preditor B1 (Pr(>|t|)). O coeficiente angular da reta da amostra (b=0.04092) é significativamente diferente de zero, sendo o p-valor do teste 6.99e-05 \*\*\* O coeficiente de determinação (Multiple R-squared) é 0.716, indicando que 71.6% da variabilidade da perda de sangue (o quanto varia em relação ao valor de perda média da amostra) é explicada pelo aumento do número de vermes.

Gerando intervalo de confiança para os parâmetros estimados. O intervalo de confiança estima quanto, em média, é a perda sanguínea de um grupo de pacientes com determinado número de vermes

```
confint(lm_suwit)
```

```
## 2.5 % 97.5 %
## (Intercept) -0.62113883 22.31579336
## vermes 0.02548089 0.05636321
```

A cada aumento de 1 verme, ocorre um aumento de 0.04 (95%IC 0.026 - 0.056) na perda de sangue.

Estimando intervalo de predição para cada observação do banco. O intervalo de predição prediz a perda de sangue para um paciente que apresenta determinado número de vermes

```
suwit_pred <- predict(lm_suwit, interval = 'predict')</pre>
```

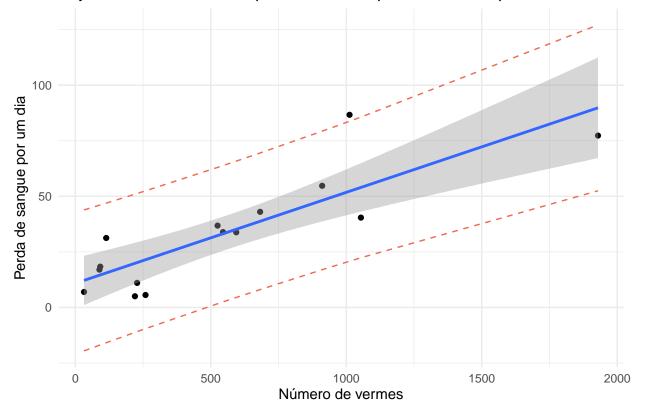
## Warning in predict.lm(lm\_suwit, interval = "predict"): predictions on current data refer to \_future\_

Incluindo o intervalo de predição para cada observação do banco

```
suwit <- cbind(suwit, suwit_pred)</pre>
```

Gerando um gráfico contendo intervalo de confiança e intervalo de predição





A faixa cinza corresponde ao intervalo de confiança e as linhas laranja são os limites do intervalo de predição.

#### Fat\_dat dataset

Estudo Fat\_dat "Fitting Percentage of Body Fat to Simple Body Measurements"

```
fat_dat <- read_sav("Bancos/fat_dat.sav")</pre>
```

Primeiro passo: verificar o banco e corrigir os erros de digitação:

- The body densities for cases 48, 76, and 96, for instance, each seem to have one digit in error as can be seen from the two body fat percentage values.
- Case 42) over 200 pounds in weight who is less than 3 feet tall (the height should presumably be 69.5 inches, not 29.5 inches)!
- The percent body fat estimates are truncated to zero when negative (case 182)

```
# Altura
fat_dat$altura_pol <- ifelse( fat_dat$numero == 42, 69.5, fat_dat$altura_pol)
# Densidades

fat_dat$densidade <- ifelse( fat_dat$numero == 48, 1.0865, fat_dat$densidade)
fat_dat$densidade <- ifelse( fat_dat$numero == 76, 1.0566, fat_dat$densidade)
fat_dat$densidade <- ifelse( fat_dat$numero == 96, 1.0591, fat_dat$densidade)

compare_fat <- compareGroups( ~ ., data = fat_dat)

summary(compare_fat)

##</pre>
```

```
##
   --- Descriptives of each row-variable ---
##
    _____
##
##
  row-variable: numero
##
##
            mean sd
                           lower
                                    upper
##
   [ALL] 252 126.5 72.89033 117.4569 135.5431
##
   _____
##
## row-variable: fat_Brozek
##
        N mean
##
                     sd
                              lower
                                       upper
  [ALL] 252 18.93849 7.750856 17.97689 19.9001
##
##
## row-variable: fat_Siri
##
##
            mean
                     sd
                             lower
   [ALL] 252 19.15079 8.36874 18.11253 20.18906
##
##
##
## row-variable: densidade
##
##
            mean
                     sd
                              lower
                                       upper
   [ALL] 252 1.055455 0.018909 1.053109 1.057801
##
##
##
## row-variable: idade
##
                              lower
            mean
                     sd
## [ALL] 252 44.88492 12.60204 43.32146 46.44838
##
```

```
## -----
## row-variable: Peso em libras
    N mean sd lower upper
## [ALL] 252 178.9244 29.38916 175.2783 182.5706
## -----
## row-variable: altura_pol
##
                      lower
     N mean
                sd
## [ALL] 252 70.30754 2.609583 69.98378 70.6313
## row-variable: kg/m2
##
   N mean sd
                        lower upper
## [ALL] 252 25.4369 3.648111 24.9843 25.88951
## -----
## row-variable: peso da massa magra
##
     N mean sd lower upper
## [ALL] 252 143.7139 18.23164 141.452 145.9758
## -----
## row-variable: Circunferencia do pescoço
     N mean sd lower upper
## [ALL] 252 37.99206 2.430913 37.69047 38.29365
## -----
## row-variable: Circunferencia do peito
     N mean sd lower upper
## [ALL] 252 100.8242 8.430476 99.77829 101.8701
## -----
## row-variable: Circ do abdomem
##
                sd lower
      N mean
## [ALL] 252 92.55595 10.78308 91.21816 93.89375
## -----
## row-variable: circ do quadril
  N mean sd lower
## [ALL] 252 99.90476 7.164058 99.01596 100.7936
## -----
## row-variable: circ do coxa
##
                sd lower
      N mean
## [ALL] 252 59.40595 5.249952 58.75462 60.05728
##
```

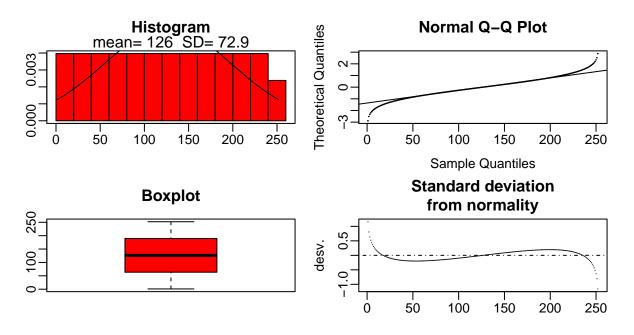
```
## -----
## row-variable: circ do joelho
    N mean sd lower upper
##
## [ALL] 252 38.59048 2.411805 38.29126 38.8897
## -----
## row-variable: circ do tornozelo
##
                     lower
       N mean
                 sd
## [ALL] 252 23.10238 1.694893 22.89211 23.31266
## row-variable: circ do biceps
## N mean sd lower
                                upper
## [ALL] 252 32.27341 3.021274 31.89858 32.64825
## row-variable: circ do antebraco
##
    N mean sd lower upper
## [ALL] 252 28.66389 2.020691 28.41319 28.91458
## -----
## row-variable: circ do pulso
                                upper
     N mean sd lower
## [ALL] 252 18.22976 0.933585 18.11394 18.34559
tabela_fat <- createTable(compare_fat)</pre>
tabela_fat
## -----Summary descriptives table -----
```

```
##
## _________
                           [ALL] N
##
                           N=252
## -----
## numero
                        126 (72.9) 252
                       18.9 (7.75) 252
## fat_Brozek
                       19.2 (8.37) 252
1.06 (0.02) 252
## fat_Siri
## densidade
                    44.9 (12.6) 252
179 (29.4) 252
70.3 (2.61) 252
## idade
## Peso em libras
## altura_pol
## kg/m2
                       25.4 (3.65) 252
## peso da massa magra 144 (18.2) 252
## Circunferencia do pescoço 38.0 (2.43) 252
## Circunferencia do peito 101 (8.43) 252
## Circ do abdomem 92.6 (10.8) 252
                  99.9 (7.16) 252
## circ do quadril
```

```
## circ do coxa 59.4 (5.25) 252
## circ do joelho 38.6 (2.41) 252
## circ do tornozelo 23.1 (1.69) 252
## circ do biceps 32.3 (3.02) 252
## circ do antebraco 28.7 (2.02) 252
## circ do pulso 18.2 (0.93) 252
```

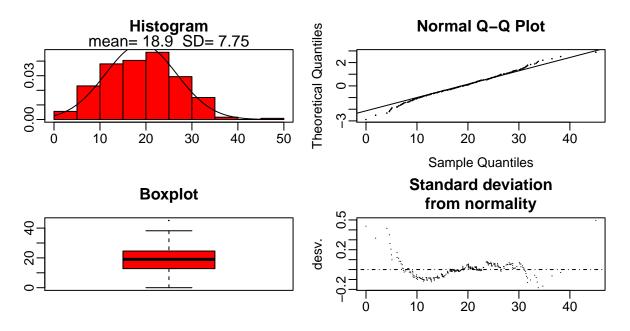
plot(compare\_fat)

### Normality plots of 'numero'



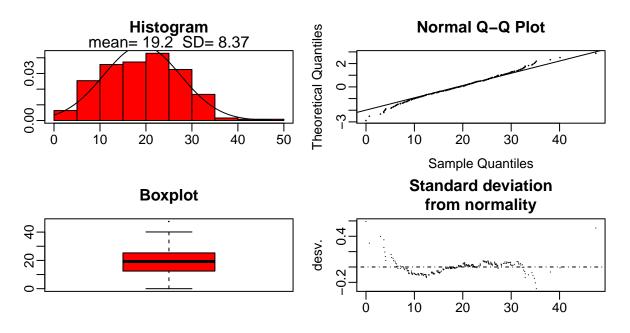
Shapiro-Wilks p-value: <0.001

### Normality plots of 'fat\_Brozek'



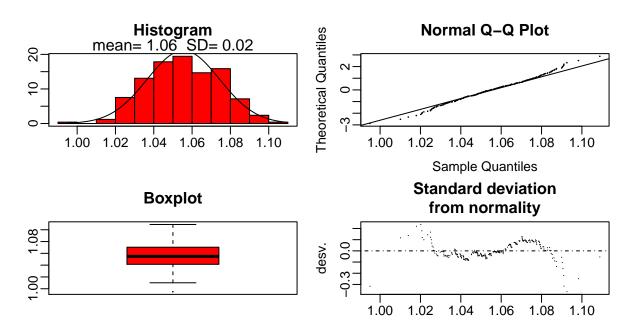
Shapiro-Wilks p-value: 0.275

# Normality plots of 'fat\_Siri'



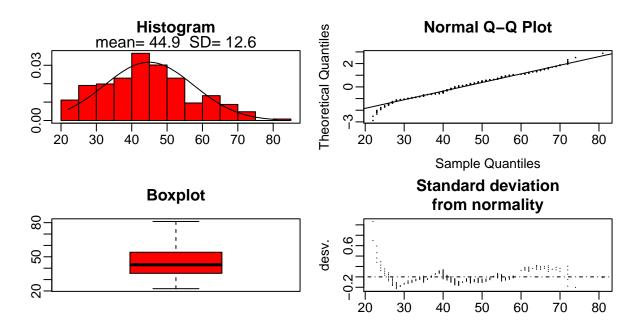
Shapiro-Wilks p-value: 0.165

### Normality plots of 'densidade'



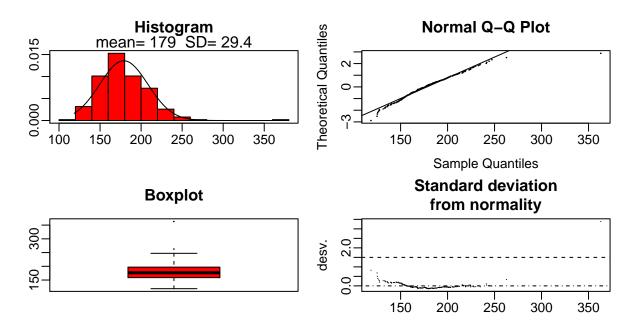
Shapiro-Wilks p-value: 0.522

# Normality plots of 'idade'



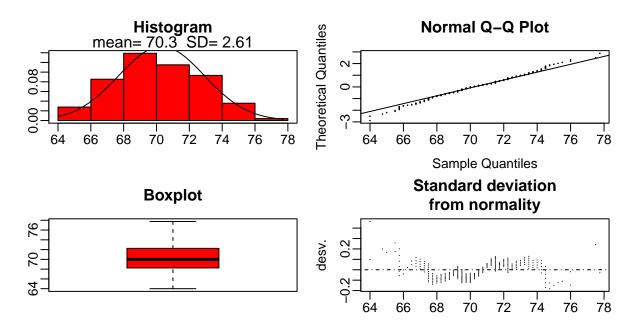
Shapiro-Wilks p-value: 0.001

### Normality plots of 'Peso em libras'



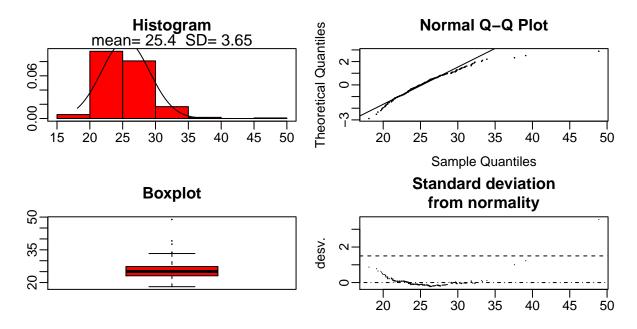
Shapiro-Wilks p-value: <0.001

### Normality plots of 'altura\_pol'



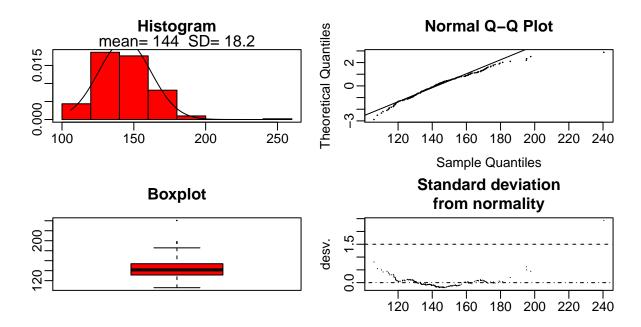
Shapiro-Wilks p-value: 0.237

### Normality plots of 'kg/m2'



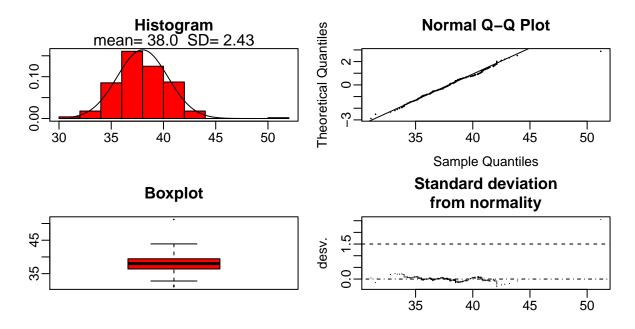
Shapiro-Wilks p-value: <0.001

#### Normality plots of 'peso da massa magra'



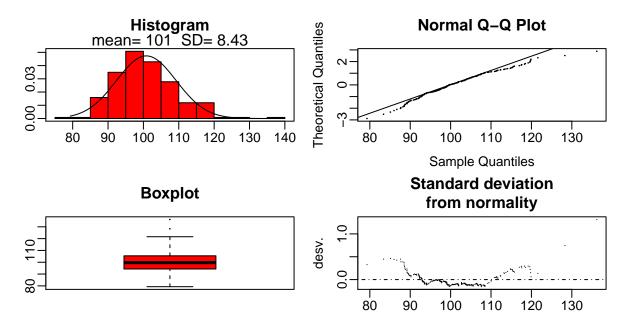
Shapiro-Wilks p-value: <0.001

### Normality plots of 'Circunferencia do pescoço'



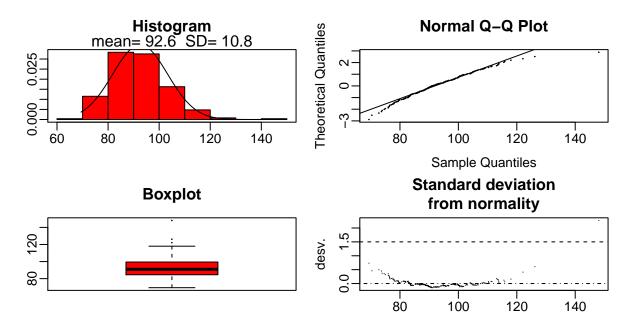
Shapiro-Wilks p-value: <0.001

### Normality plots of 'Circunferencia do peito'



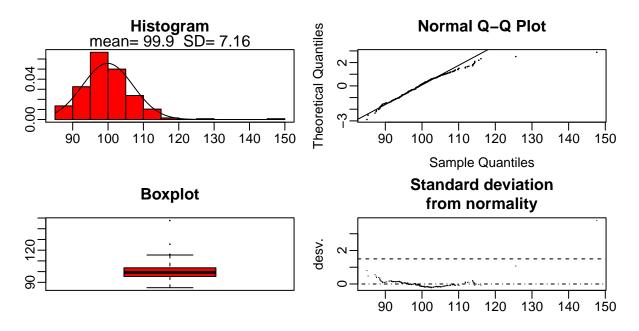
Shapiro-Wilks p-value: <0.001

### Normality plots of 'Circ do abdomem'



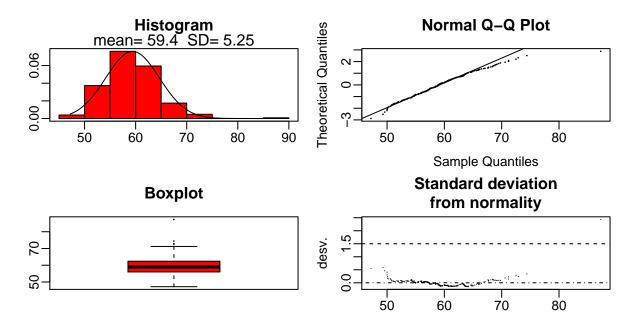
Shapiro-Wilks p-value: <0.001

#### Normality plots of 'circ do quadril'



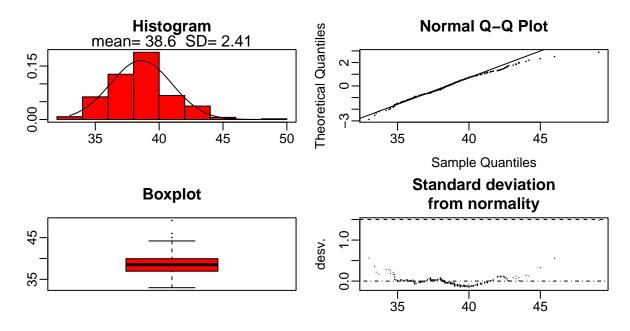
Shapiro-Wilks p-value: <0.001

### Normality plots of 'circ do coxa'



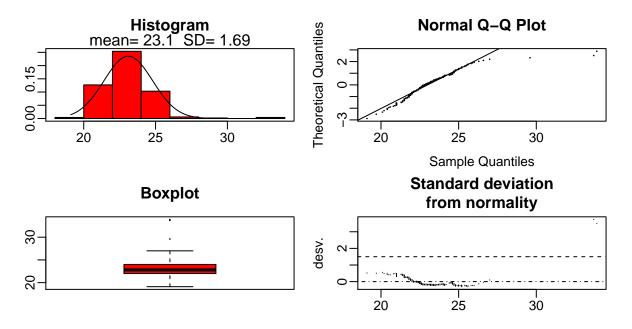
Shapiro-Wilks p-value: <0.001

### Normality plots of 'circ do joelho'



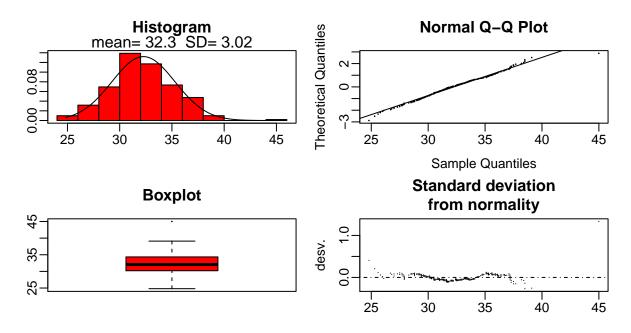
Shapiro-Wilks p-value: 0.003

### Normality plots of 'circ do tornozelo'



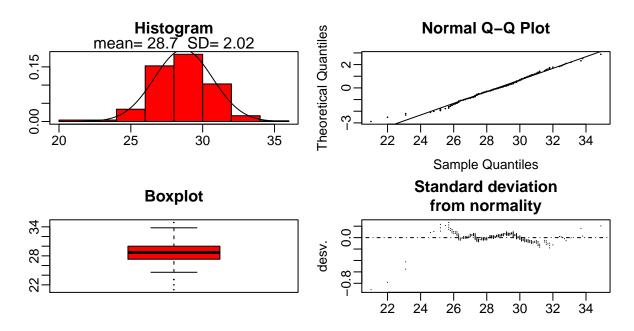
Shapiro-Wilks p-value: <0.001

### Normality plots of 'circ do biceps'



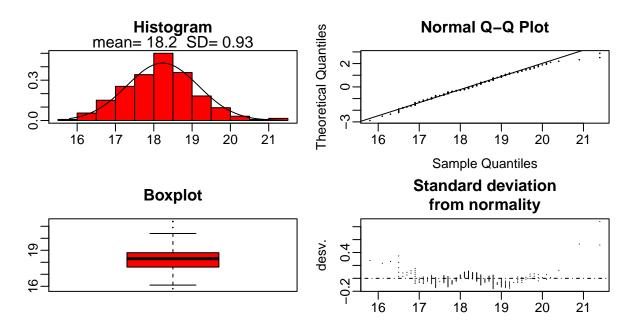
Shapiro-Wilks p-value: 0.046

### Normality plots of 'circ do antebraco'



Shapiro-Wilks p-value: 0.048

#### Normality plots of 'circ do pulso'



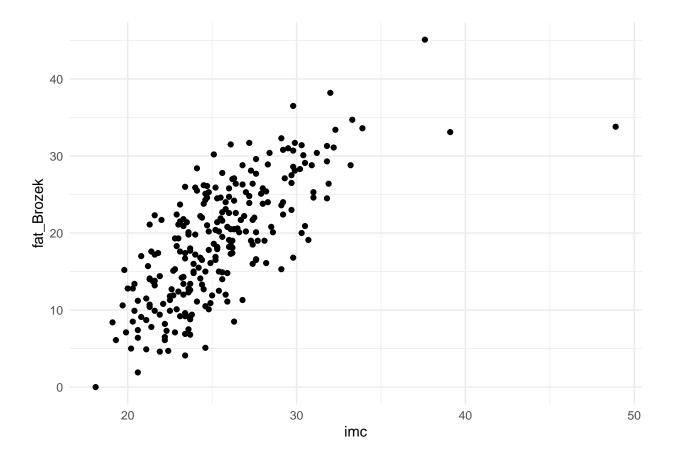
Shapiro-Wilks p-value: 0.064

Segundo passo: verificar linearidade com gráfico de dispersão. Identificar pontos

1) Gráfico de dispersão

```
disp_fat_Brozek<- ggplot(fat_dat, aes(x = imc, y = fat_Brozek))+
  geom_point() +
  theme_minimal()

disp_fat_Brozek</pre>
```



2) Identificando pontos outliers: outlier na horizontal

```
fat_dat %>%
  filter(imc>40)
## # A tibble: 1 x 19
##
     numero fat_Brozek fat_Siri densidade idade peso_lbs altura_pol
      <dbl>
                                                    <dbl>
##
                 <dbl>
                          <dbl>
                                     <dbl> <dbl>
                                                               <dbl> <dbl>
## 1
         39
                  33.8
                           35.2
                                      1.02
                                                     363.
                                                                72.2 48.9
## # ... with 11 more variables: FFW <dbl>, pescoco <dbl>, peito <dbl>,
       abdomen <dbl>, quadril <dbl>, coxa <dbl>, joelho <dbl>,
       tornozelo <dbl>, biceps <dbl>, antebraco <dbl>, pulso <dbl>
```

#### Terceiro passo: estimar modelo

```
##
## Call:
## lm(formula = fat_Brozek ~ imc, data = fat_dat)
##
```

```
## Residuals:
       Min
                    Median
##
                 1Q
                                  30
                                          Max
## -21.4292 -3.4478
                    0.2113 3.8663 11.7826
##
## Coefficients:
##
               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -20.40508
                           2.36723
                                    -8.62 7.78e-16 ***
                                    16.79 < 2e-16 ***
                1.54671
                           0.09212
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## Residual standard error: 5.324 on 250 degrees of freedom
## Multiple R-squared: 0.53, Adjusted R-squared: 0.5281
## F-statistic: 281.9 on 1 and 250 DF, p-value: < 2.2e-16
```

Estimando intervalo de confiança

```
confint(lm_imc_brozek)
```

```
## 2.5 % 97.5 %
## (Intercept) -25.067331 -15.74283
## imc 1.365275 1.72815
```

A cada aumento de 1 unidade no IMC ocorre aumento de 1.55% na gordura corporal pelo índice Brozek. O intervalo de confiança é de 1.36 a 1.73.

Estimando intervalo de predição

```
brozek_pred <- predict(lm_imc_brozek, interval = "predict")</pre>
```

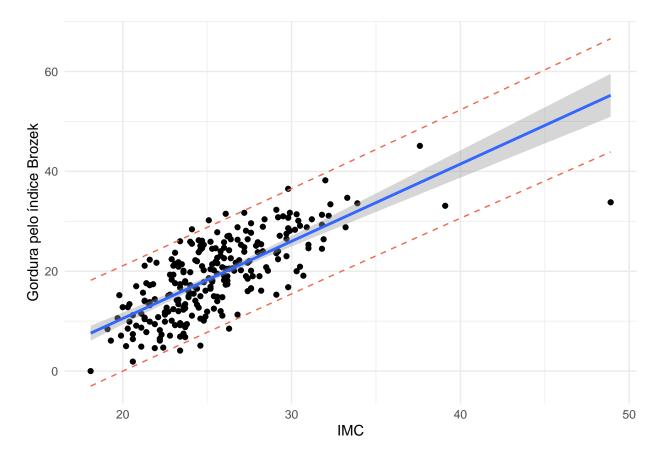
## Warning in predict.lm(lm\_imc\_brozek, interval = "predict"): predictions on current data refer to \_fu

Incluindo o intervalo de predição para cada observação do banco

```
dat_brozek <-cbind(fat_dat, brozek_pred)</pre>
```

Gerando um gráfico com intervalo de confiança e intervalo de predição

```
plot_fat_Brozek <- ggplot(dat_brozek, aes(x = imc, y = fat_Brozek))+
  geom_point() +
  geom_smooth (method = "lm",)+
  scale_x_continuous("IMC") +
  scale_y_continuous("Gordura pelo indice Brozek") +
  theme_minimal() +
  geom_line(aes(y = lwr), col = "coral2", linetype = "dashed") +  geom_line(aes(y = upr), col = "coral")
plot_fat_Brozek</pre>
```



Gerando um modelo para predizer a gordura segundo Siri conforme o IMC

```
##
## Call:
## lm(formula = fat_Siri ~ imc, data = fat_dat)
##
## Residuals:
##
       Min
                 1Q
                      Median
                                   3Q
                                           Max
  -23.1070 -3.7418
                      0.2101
                               4.2070
                                       12.8114
##
##
  Coefficients:
##
               Estimate Std. Error t value Pr(>|t|)
## (Intercept) -23.29940
                           2.55796
                                    -9.109
                                             <2e-16 ***
                           0.09955 16.764
                                             <2e-16 ***
## imc
                 1.66884
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.753 on 250 degrees of freedom
## Multiple R-squared: 0.5292, Adjusted R-squared: 0.5273
## F-statistic: 281 on 1 and 250 DF, p-value: < 2.2e-16
```

Gerando intervalo de confiança para os parâmetros estimados

```
confint(lm_imc_siri)
```

```
## 2.5 % 97.5 %
## (Intercept) -28.337296 -18.261512
## imc 1.472787 1.864899
```

Para o aumento de 1 ponto no IMC ocorre aumento de 1.7% (95%IC 1.5-1.86) na gordura corporal. O modelo explica 52% da variabilidade da gordura corporal.

Gerando um intervalo de predição para cada observação do banco na variável fat\_siri

```
siri_pred <- predict(lm_imc_siri, interval = "predict")</pre>
```

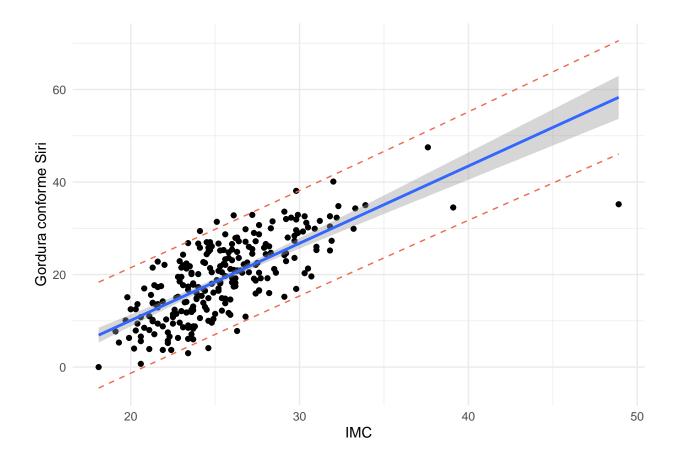
## Warning in predict.lm(lm\_imc\_siri, interval = "predict"): predictions on current data refer to \_futu

Incluindo o intervalo de predição para cada observação do banco

```
dat_siri <-cbind(fat_dat, siri_pred)</pre>
```

Gerando gráfico com intervalo de confiança e intervalo de predição

```
plot_fat_siri <- ggplot(dat_siri, aes(x = imc, y = fat_Siri))+
  geom_point() +
  geom_smooth (method = "lm",)+
  scale_x_continuous("IMC")+
  scale_y_continuous("Gordura conforme Siri")+
  theme_minimal() +
  geom_line(aes(y = lwr), col = "coral2", linetype = "dashed") +  geom_line(aes(y = upr), col = "coral")
plot_fat_siri</pre>
```



#### Anscombe dataset

Famoso banco de dados criado por Francis Anscombe com propriedades numéricas idênticas (estatísticas resumo e linhas de regressão), mas diferentes formas funcionais

Esse banco está disponível no R, basta chamá-lo

```
anscombe_dataset <- data("anscombe")</pre>
```

Estatísticas descritivas

```
##
## -----Summary descriptives table -----
##
##
[ALL] N
##
N=11
```

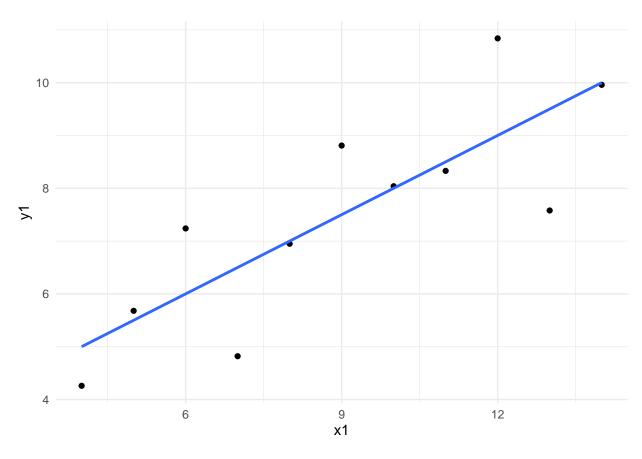
```
## x1 9.00 (3.32) 11
## x2 9.00 (3.32) 11
## x3 9.00 (3.32) 11
## x4 9.00 (3.32) 11
##
```

Criando gráfico de dispersão para os 4 bancos dentro de Anscombe

Banco 1

```
x1_scatter <- ggplot(anscombe, aes(x = x1, y = y1))+
  geom_point() +
  theme_minimal()+
  geom_smooth(method = "lm", se = FALSE)

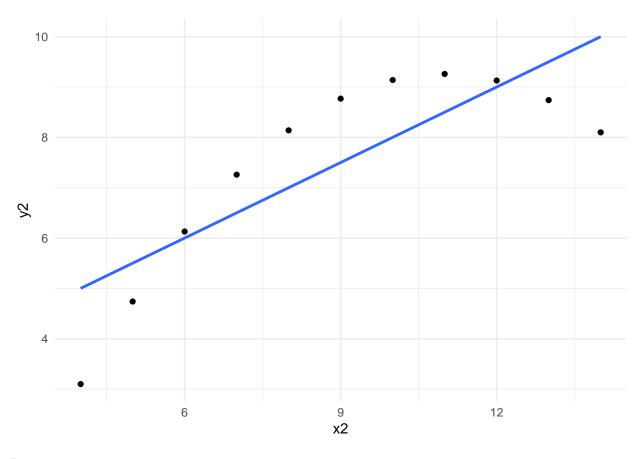
x1_scatter</pre>
```



Banco 2

```
x2_scatter <- ggplot(anscombe, aes(x = x2, y = y2))+
  geom_point() +
  theme_minimal() +
  geom_smooth(method = "lm", se = FALSE)

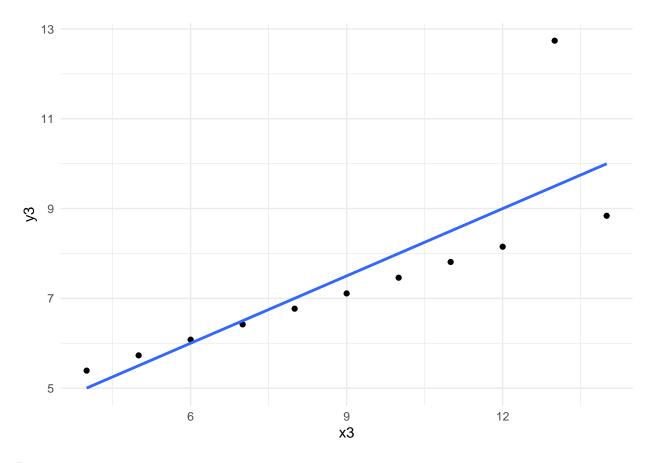
x2_scatter</pre>
```



#### Banco 3

```
x3_scatter <- ggplot(anscombe, aes(x = x3, y = y3))+
  geom_point() +
  theme_minimal() +
  geom_smooth(method = "lm", se = FALSE)

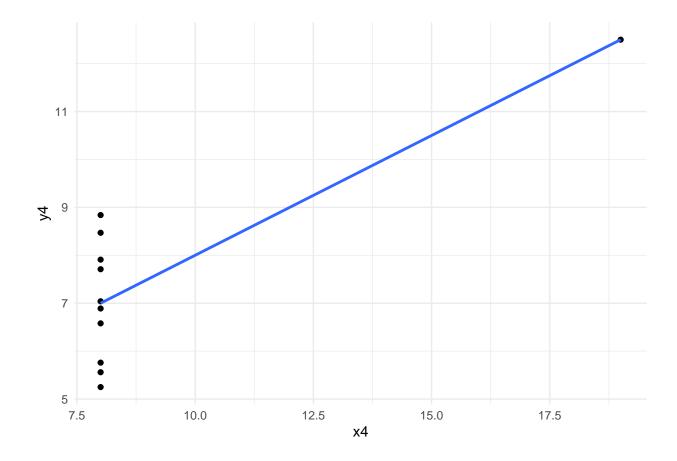
x3_scatter</pre>
```



#### Banco 4

```
x4_scatter <- ggplot(anscombe, aes(x = x4, y = y4))+
  geom_point() +
  theme_minimal() +
  geom_smooth(method = "lm", se = FALSE)

x4_scatter</pre>
```



Diagnóstico em regressão linear simples